发件人: Yulin Wu yw4923@nyu.edu

主题

日期: 2020年9月9日 下午5:34

收件人:



Adaptive boosting

2020年9月6日 星期日

Motivation:

给出10张苹果的图片。10张不是苹果的图片,希望能教会小学生们如何辨别苹果。

老师:一开始。这20张图片都同样重要,michael你来说说看如何辨别苹果呢?

michael说: 苹果是circular的。根据这个circular分类器,有些图片被分对了,有些被分错了。(如false positive, false negative)

★ 此时,全班的小学生知道了苹果是circular的。

老师:现在将被分错的图片都放大,分对的图片维小。那么现在,nina你说说看如何辨别苹果呢?



Tina: 苹果是red的。根据这个red的分类器,有些图片被分对了,有些被分错了。

★ 此时,全班的小学生知道了苹果是circular的,也是red的。

老师:现在将被分错的图片都放大。分对的图片细小。那么现在,Joey你说说着如何辨别苹果呢?



Joey: 苹果可能是green的。

🛊 此时,全班的小学生知道了苹果是circular的,也是red的,也可能是green的。

Boosting:

上述的过程中,一个小学生的判断就是一个分类器。者师的动作就是:每训练一个分类器,就将其把错误的数据 权重加大,来训练下一个分类器。而全班同学学到的就是这些分类器的blending,又因为这些分类器的权重相 当于boostrapping,所以全班同学学到的是这些分类器的bagging。

boosting的性质:

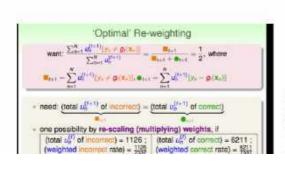
- 能保证分类器的diversity。 直观来讲,g_2是在g_1做不好的数据集上做得好,那么他们肯定会挺不一样的。
- 2. e_in 和 e_out 相差不大。
- 3. 效率高,能在log(N)的时间内将e_in训练接近0.

性质1的严格证明:

$$\begin{split} & \quad \mathbf{g}_t & \leftarrow & \underset{h \in \mathcal{H}}{\operatorname{argmin}} \left(\sum_{n=1}^N \mathbf{u}_n^{(l)} \left[\mathbf{y}_n \neq h(\mathbf{x}_n) \right] \right) \\ & \quad \mathbf{g}_{t+1} & \leftarrow & \underset{h \in \mathcal{H}}{\operatorname{argmin}} \left(\sum_{n=1}^N \mathbf{u}_n^{(l+1)} \left[\mathbf{y}_n \neq h(\mathbf{x}_n) \right] \right) \end{split}$$

if g_l 'not good' for $\mathbf{u}^{(t+1)} \Longrightarrow g_l$ -like hypotheses not returned as g_{l+1}

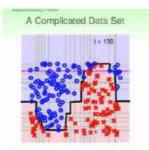
要保证 g_t 在 g_t +1的权重数据集上表现得不好,即我要令 $\frac{\sum_{i=1}^{N} v^{i+1} [(\sum_{i=1}^{N} (c_i)]]}{\sum_{i=1}^{N} v^{i+1}}$

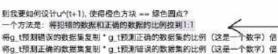


Bootstrapping as Re-weighting Process $\mathcal{D} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_3, y_2), (\mathbf{x}_4, y_4)\}$ $\begin{array}{c} \text{totalise} \quad \mathcal{D}_1 = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_4, y_4)\} \\ \mathcal{E}_2^*(n) = \frac{1}{4} \sum_{i=1}^{4} \underbrace{\bigcup_{i \in \mathcal{V}} \{\mathbf{x}_i \in \mathcal{V}(\mathbf{x}_i)\}}_{\{\mathbf{x}_i \in \mathcal{V}(\mathbf{x}_i)\}} \underbrace{\begin{cases} \mathbf{x}_i, y_1, (\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_4, y_4) \\ \mathbf{x}_i, y_1, (\mathbf{x}_1, y_4), (\mathbf{x}_1, y_4) \\ \mathbf{x}_i, y_2, (\mathbf{x}_1, y_4), (\mathbf{x}_1, y_4) \\ \mathbf{x}_i, y_2, (\mathbf{x}_1, y_4), (\mathbf{x}_1, y_4) \\ \mathbf{x}_i, y_2, (\mathbf{x}_1, y_4) \\ \mathbf{x}_i, y_i, (\mathbf{x}_1, y_4) \\$

Theoretical Guarantee of AdaBoost

From VC bound $\mathcal{E}_{\mathrm{nd}}(G) \leq \mathcal{E}_{\mathrm{n}}(G) + O\left(\underbrace{O(d_{\mathrm{nd}}(H),\bigcap_{g \in \mathcal{G}}\log N)}_{g \in \mathcal{G}} |\log N\right)$ • first term can be small: $\mathcal{E}_{N}(G) = 0 \text{ after } T = O(\log N) \text{ terations if } r_{1} \leq s \leq \frac{1}{s} \text{ always}$ • second term can be small: overall d_{nd} grows "slowly" with T





```
根据这个思想、我们定义要形。t 正比例于 1 - epsilon_t, 反比例于 epsilon_t.  
Scaling Factor 'optimal' re-weighting: let \epsilon_t = \frac{\sum_{k=1}^N u_k^{(t)}[y_k + y_k^{(t)}]}{\sum_{k=1}^N u_k^{(t)}}, multiply incorrect \propto (1-\epsilon_t); multiply correct \propto \epsilon_t define scaling factor \Phi_t = \sqrt{\frac{1-\epsilon_t}{\epsilon_t}}.

**noorrect \leftarrow incorrect \leftarrow correct \rightarrow \leftarrow correct \leftarrow correct \rightarrow \leftarrow incorrect \rightarrow \leftarrow correct \rightarrow \leftarrow correct \rightarrow \rightarrow \leftarrow equivalent to optimal re-weighting \bullet \bullet_t \geq 1 iff \epsilon_t \leq \frac{1}{2} —physical meaning: scale up incorrect; scale down correct —like what Teacher does
```

看到了吗! 发现能够保证g_t 和g_t+1很不同的条件就是: scale up incorrect, scale down correct. 放展则才老师做的事情,证明了boosting的性质1.

如果让e:表示犯错的比例那么

'optimal' re-weighting: let $\epsilon_t = \frac{\sum_{n=1}^{N} u_n^{(n)} |y_n \neq y_n(x_n)|}{\sum_{n=1}^{N} u_n^{(n)}}$

multiply incorrect $\propto (1 - \epsilon_f)$; multiply correct $\propto \epsilon_f$

boosting algorithm 流程:

```
to t=1,2,\ldots,T

obtain g_t by \mathcal{A}(\mathcal{D},\mathbf{u}^{(t)}), where \mathcal{A} tries to minimize \mathbf{u}^{(t)}-weighted 0/1 error

update \mathbf{u}^{(t)} to \mathbf{u}^{(t+1)} by \phi_t = \sqrt{\frac{1-c_t}{c_t}}, where e_t weighted error (\text{incorrect}) rate of g_t return G(\mathbf{x}) = ?

want g_t 'best' for E_n: \mathbf{u}_n^{(t)} = \frac{1}{N}

G(\mathbf{x}):

uniform? but g_t very bad for E_n (why? >))

linear, non-linear? as you wish

next: a special algorithm to aggregate linearly on the fly with theoretical guarantee
```